

**KARADENİZ TEKNİK ÜNİVERSİTESİ**  
**FEN BİLİMLERİ ENSTİTÜSÜ**

**BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI**

**HİPERSPEKTRAL UYDU GÖRÜNTÜLERİNİN SINIFLANDIRILMASINDA**  
**VAE VE CNN İLE HİBRİK BİR YAKLAŞIM**

**YÜKSEK LİSANS SEMİNER ÇALIŞMASI RAPORU**

**Öğrencinin Adı Soyadı : Murat Can VARER**

**Öğrenci No : 379438**

**Danışman : Dr. Öğr. Üyesi Murat AYKUT**

**Seminer Sunum Tarihi : 21 /01 /2021**

## İÇİNDEKİLER

	<u>Sayfa No</u>
ŞEKİLLER DİZİNİ .....	II
TABLolar DİZİNİ .....	III
1. Giriş .....	1
2. Genel Bilgiler .....	2
3. Literatür Taraması .....	5
4. Konuyla İlgili Çalışmalar .....	11
5. Sonuçlar .....	15
6. Kaynaklar .....	17

## ŞEKİLLER DİZİNİ

	<b><u>Sayfa No</u></b>
Şekil 3.1 ASSFLN modelinin genel olarak çalışma şekli .....	5
Şekil 3.2 BERT modelinin genel olarak çalışma şekli .....	6
Şekil 3.3 HybridSN modelinin genel olarak çalışma şekli .....	7
Şekil 3.4 GAO modelinin genel olarak çalışma şekli .....	8
Şekil 3.5 SSDC-DenseNet modelinin genel olarak çalışma şekli .....	9
Şekil 3.6 3D-SRNet modelinin genel olarak çalışma şekli .....	10
Şekil 5.1 Indian Pines hedef sınıflandırma görüntüsü .....	15
Şekil 5.2 Indian Pines tahmin sonucu oluşan çıktı .....	15
Şekil 5.3 Salinas orjinal hedef sınıflandırma görüntüsü .....	16
Şekil 5.4 Salinas tahmin sonucu oluşan çıktı .....	16

## TABLÖLAR DİZİNİ

	<u>Sayfa No</u>
Tablo 5.1    Sonuçların sayısal değeleri .....	16

## 1. Giriş

Yüksek hesaplamaların daha hızlı yapıldığı günümüz teknolojisinde artık işlem yükü fazla olan projeler daha kolaylıkla yapılmaktadır. Evrişimli sinir ağları (ESA) (Convolution Neural Networks (CNN) ) görüntüler için sınıflandırma problemlerini çözmek amaçlı geliştirilmiş bir derin öğrenme modelidir. Uzaktan algılama, dünyanın yüzeyi hakkında bilgi edinme bilimidir. Günümüzde uzaktan algılama başta askeri hava sahası olmak üzere deprem hazırlığı aşamasında toplanma bölgelerinin de belirlenmesinde önemli rol oynamaktadır. Derin öğrenme, öğrenme düzeylerini temsil eden makine öğrenmesinin dalını ifade eder yani burada bahsi geçen derin kelimesi, sınıflandırılacak görüntülerin özelliklerini sinir ağı yapısının derinliğinden alır. Varyasyonel Oto-Kodlayıcı (VOK) (Variational AutoEncoder (VAE) ), temelde yarı-danışmalı öğrenme olarak kullanılan bir yöntemdir. Amaç görüntülerin boyutu küçülterek daha farklı görüntülerin elde edilmesi için gizli katman adı verilen alanda Gaussian gürültüsü uygulayarak temelde çeşitliliği arttırmaktır. Bu tez çalışmasında uydudan çekilmiş Hiperspektral Görüntüleri (Hiperspectral Images (HSI) ) CNN modelini kullanarak sınıflandırılması yapılacaktır.

## 2. Genel Bilgiler

Hiperspektral Görüntüleme (HSG), yüzey materyallerinden yansıyan enerjinin, dar ve bitişik çok sayıda dalga boyu bandında ölçümüdür. Hiperspektral sensörler kullanılarak elde edilen veriler ilk iki boyut uzamsal üçüncü boyut spektral bilgiyi içeren hacimsel verilerdir. Ayrıca her bir piksel yüksek boyutlu vektörlerden oluşmaktadır. Elektromanyetik spektrum bandında hem görünür hem de kızılötesi bölgesinde birçok dalga boyunda görüntüler elde edebilen HSG, daha az sayıda görüntüler elde edebilen multispektral görüntülemeye göre daha anlamlı özellikler içermektedir. Bu özellikler farklı nesneleri tespit etmede yardımcı olabilmektedir. HSG kullanılarak nesnelerin tespiti ve sınıflandırılması gibi son zamanlardaki çalışmalar, bağlamsal özelliklerin büyük avantajlar sağlayabileceğini göstermiştir (Lee ve Kwon, 2016; Chu ve ark., 2018).

Hiperspektral görüntülerin sınıflandırılmasında en yakın komşu, karar ağaçları, destek vektör makinesi (DVM) ve yapay sinir ağları (YSA) gibi farklı makine öğrenmesi temelli metotlar kullanılmaktadır. En yakın komşu metodu Öklid uzaklığı kullanan sınıflandırılma yöntemidir. [1]. DVM çekirdek metodu kullanarak yüksek boyutlu uzayda farklı hiperspektral sınıflar arasında sınıflandırma sınırı belirlenmektedir [2]. DVM kadar yüksek sınıflandırma doğruluğu elde edememelerine rağmen, YSA kullanılarak yapılan hiperspektral görüntü sınıflandırma çalışmaları da bulunmaktadır [3]. Bu tür geleneksel spektral sınıflandırıcıların çoğu hiperspektral görüntülerdeki bazı bölgelerin tespit edilip ayırt edilmesinde halen yetersiz kalabilmektedir. Bunun temel nedeni sınırlı sayıda etiketlenmiş hiperspektral görüntü verisinin bulunmasıdır [4].

Derin öğrenme metotlarından birisi olan Evrişimli Sinir Ağı (ESA) nesne algılama (Ren ve ark., 2015), görüntü sınıflandırma (Wang ve ark., 2016), derinlik tahmini (Liu ve ark., 2015), anlamsal bölümlendirme (Gidaris ve Komodakis, 2015), cilt kanseri sınıflandırması (Saba ve ark., 2019) gibi alanlarda yüksek başarımlara sahiptir. Bunun sebebi, ESA'nın çok fazla ön işleme olmadan ağda bulunan gizli katmanlar ile özellikleri çıkarabilmesidir.

Hiperspektral görüntü sınıflandırmada karşılaşılan bir diğer zorluk ise farklı maddelerin benzer spektral değerlere sahip olması durumudur. Bu durumda sadece spektral bilgi ile sınıflandırma yapmak zordur. Bu problemi çözmek için uzaysal ve spektral bilgileri birlikte kullanan markov rastgele alanlar (MRA) yöntemi kullanılmıştır [5]

Yukarıda bahsedilen metotlar görüntü özelliklerini sınıflandırmadan bağımsız bir dizi işlem ile çıkartmaktadırlar. Ayrıca gerekli durumlarda uzman deneyiminden faydalanılmakta olup parametre ayarlaması gibi bazı işlemlere de ihtiyaç duyabilmektedirler. Derin öğrenme metotları daha dinamik ve yüksek seviyeli görüntü özellikleri sunarak hiperspektral görüntülerin sınıflandırılmasında yoğun bir şekilde kullanılmaktadırlar [6], [7]. Derin sinir ağları etkin ve adaptif öğrenme modelleridir. Çok katmanlı yığılmış oto-kodlayıcı, derin Boltzmann makineleri ve evrişimsel sinir ağları yaygın bir şekilde kullanılan derin sinir ağları arasında yer almaktadır. Evrişimsel sinir ağları (ESA) iki boyutlu sinir ağı olup hem uzaysal hem de spektral bilgiyi daha iyi yakalayabilmektedir. Chen vd. [8] TBA, oto-kodlayıcı ve lojistik regresyonu birlikte kullanarak hiperspektral görüntü sınıflandırması yapan bir yöntem geliştirmişlerdir. ESA kullanan bir diğer çalışmada ise beş katmanlı bir ESA mimarisi inşa edilerek hiperspektral görüntüleri optimum şekilde analiz edebilecek bir ağ tasarlanmıştır [9]. Zabalza vd. [10] yığılmış oto-kodlayıcı kullanarak hiperspektral görüntüyü farklı bölgelere bölütlemişlerdir. Derin öğrenme modellerinin sahip olduğu ağır parametre yükü hafifletilerek geliştirilen bir ESA mimarisinde ise hiperspektral görüntülemedeki komşu piksellerin iç korelasyon bilgilerinden faydalanılmıştır [11].

Gözetimsiz bir ağ modeli olan Varyasyonel Otokodlayıcı (Variational Autoencoder (VAE) ), klasik otokodlayıcı modelinde olduğu gibi kodlayıcı (E) ve kod çözücü (G) ağlarından oluşan bir ağ modelidir. Klasik otokodlayıcı modelinde karşılaşılan gradyan düşüşü ve aşırı öğrenme problemlerini çözmek üzere otokodlayıcıya bir varyasyon terimi eklenmesi ile elde edilmiştir [12].

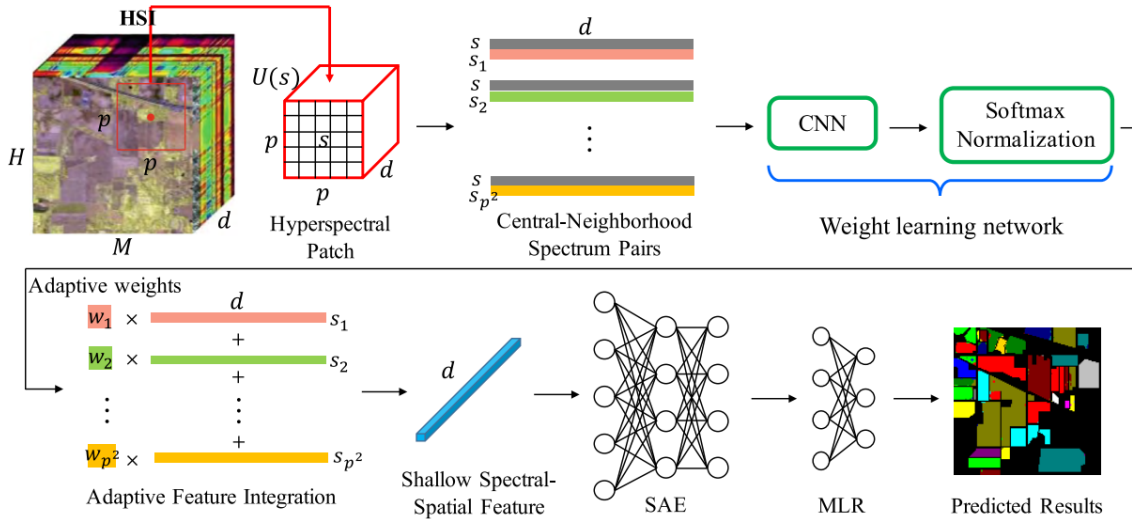
HSG verilerinin sınıflandırılmasında 2B-ESA kullanıldığında sadece uzamsal özellikler elde edilir. HSG verileri 3 boyutlu hacimsel veriler olduğu için hem uzamsal hem de spektral özelliklerin elde edilmesi gerekir (Roy ve ark., 2019). Bu özellikler 3 boyutlu konvolüsyon katmanları kullanılarak sağlanabilir. Ayrıca hiperspektral veriler için komşu pikseller büyük önem taşımaktadır. Bu nedenlerden dolayı makalede hem uzamsal hem de spektral özelliklerin elde edilmesi için 3B-ESA kullanılmıştır. Ayrıca HSG sınıflandırılmasında yeni bir yöntem olan komşuluk çıkarımı yöntemi kullanılarak komşu pikselleride içerecek şekilde mini küpler oluşturulmuştur. Bu sayede daha çok örnek kullanılarak sınıflandırılma performansının artması sağlanmıştır. Sınıflandırma performansını değerlendirmek için Indian Pines (IP), Salinas scene (SA) gibi iki uzaktan algılama veriseti kullanılmıştır. Sınıflandırma işlemi sonucunda önerilen 3B-ESA-VAE modeli yüksek başarımlar elde etmiştir.



### 3. Literatür Taraması

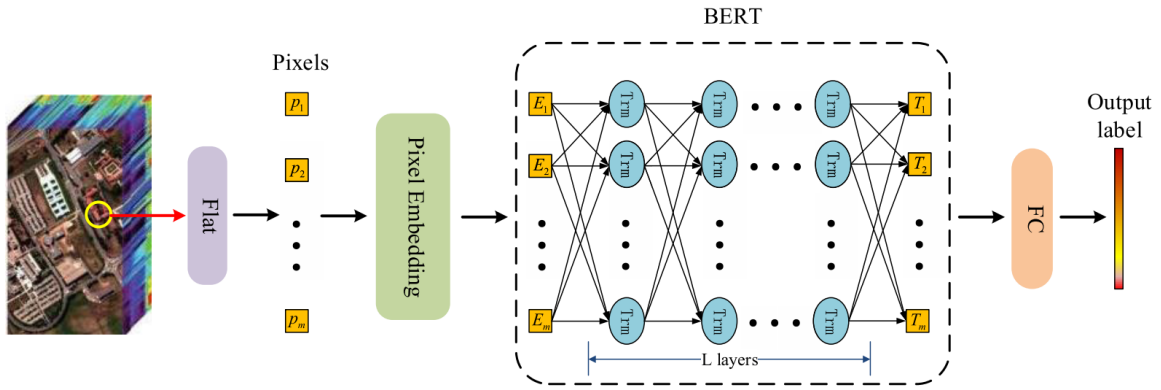
Derin öğrenme son yıllarda popüler bir araştırma konusu olmuştur. Bununla birlikte gelişen yüksek hızlı hesaplamalı ekran kartları ile büyük boyutlu görüntülerin de çalışmaları artmıştır.

Adaptive spatial-spectral feature learning network(ASSFLN) yöntemi olarak bir yöntem. İlk olarak görüntüyü parçalara bölme işlemi yapıldı ve daha sonra merkez-komşuluk spectrum çiftleri oluşturulmuştur. Bu işlem adımlarından sonra vektör olarak çıkan sonuçlar 2B olarak birleştirdi. Daha sonra bunları ESA ve SAE(Stack Autoencoder) ile birlikte kullanmış. ESA işleminden sonra softmax normalizasyon ile ağırlık öğrenme ağı oluşturmuş. Daha sonra öğrenilen her bir ağırlığın özelliğini çıkarıp bunları stack autoencoder a vermiş. Bu işlemin sonunda çıktıyı MLR( multinomial logistic regression) katmanına aktarıp sınıflandırmayı bu aşamada yapmıştır [13]. Şekil 3.1’de anlatılan modelin görsel hali verilmiştir.



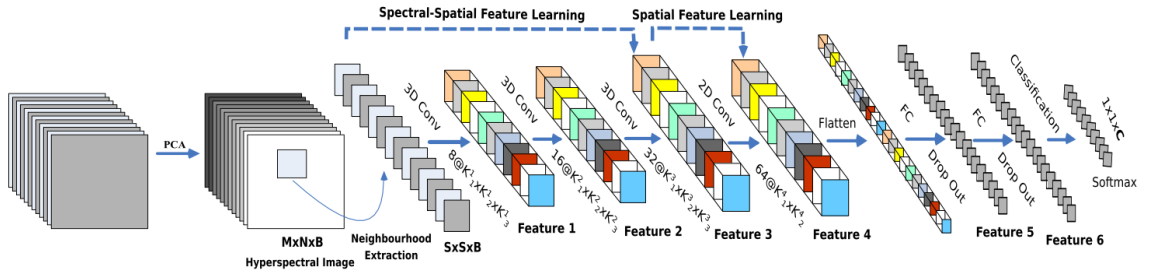
Şekil 3.1: ASSFLN modelinin genel olarak çalışma şekli

Bir başka bir yöntem ise. İlki hyperspectral görüntülerden tek tek pikselleri alıyor. Bu işlem için flat diye bir yöntem uyguluyor. Burada bahsedilen flat işlemi bu piksellerin birleştirmesini ifade ediyor. Sonra çıkardığı her bir pikselleri başka bir yöntem olan pixel gömme olarak birleştiriyor. Sonra BERT ismi verilen bir sıralı ağ veriyor. Bu işlemin ardından çıktıları tam-bağlı ağa verip burada eğittikten sonra sınıflandırma işlemi yapıyor [14]. Şekil 3.2’de anlatılan modelin görsel hali verilmiştir.




Şekil 3.2: BERT modelinin genel olarak çalışma şekli

Yöntem temel olarak sınıflardan eşit örnek alınarak farklı ESA mimarilerinden oluşturulmuştur. Bu ESA mimarileri şunlardır; 3B-ESA, 2B-ESA, D-3B ESA, D-2B ESA, D-Res-2B ESA, D-Res-3B-ESA mimarileri ile traning yapılıyor. Bunların çıktıları her birini bir vektör olarak hesaplıyor ve etiket verileri ile arasında euclidean uzaklığını hesaplıyor ve ardından yitim( loss) fonksiyonuna veriyor. Danışmanlı özellikler(Supervised feature) çıkarıp Sinir Ağı(Neural Network) sınıflandırıcı ile sınıflandırıyor. Test amaçlı SVM ve bunun türevleri olan sınıflandırıcı kullanılıyor fakat en iyi sonucu NN veriyor. Res olarak bahsedilen mimari son zamanlarda derin öğrenmede kullanılan residual olarak adı geçen yapıdır. Bir önceki ağıdan gelen çıktıyı o anki ağıdan çıkan çıktı ile toplama işlemi olarak kısaca anlatabiliriz [15]. Şekil 3.3’de anlatılan modelin görsel hali verilmiştir.



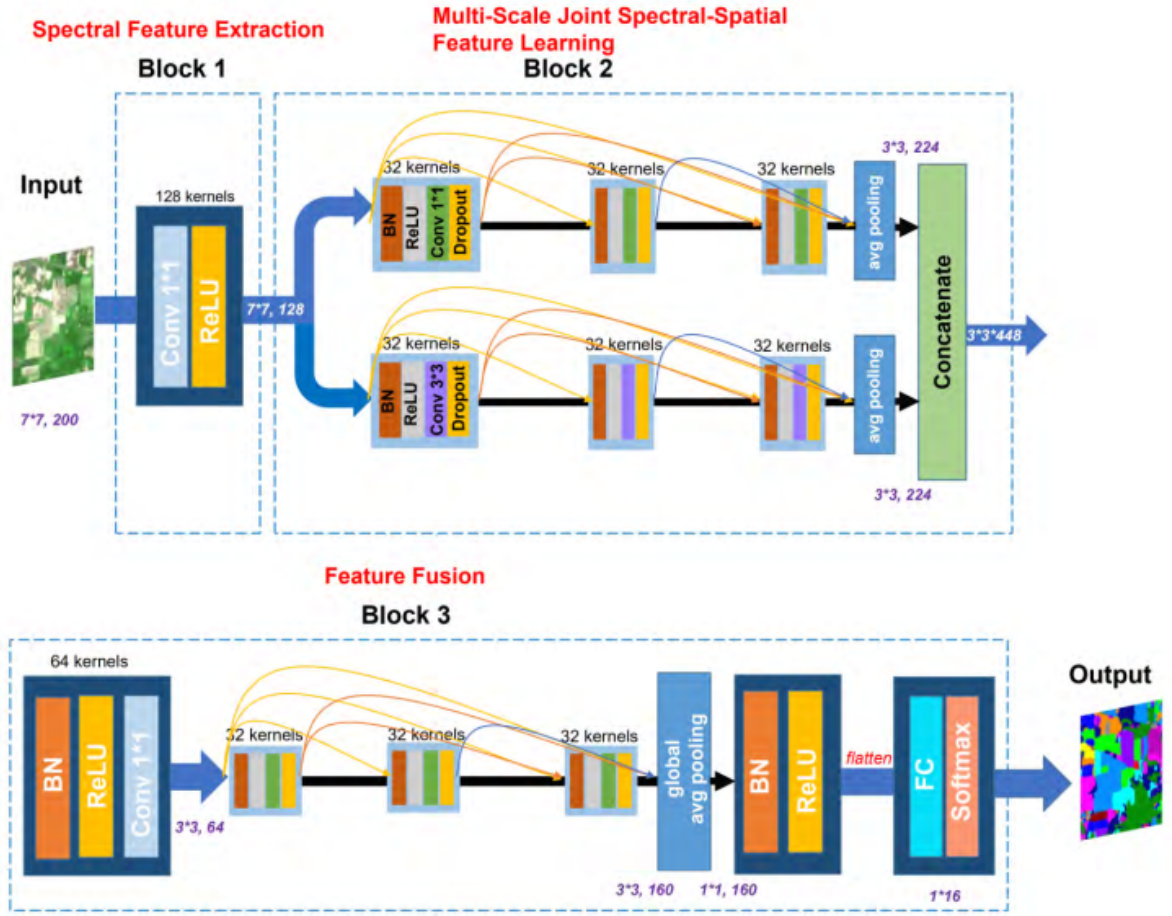
Şekil 3.3: HybridSN modelinin genel olarak çalışma şekli

Görüntü patchlere bölündükten sonra conv uygulanıp ardından pre-activation residual attention network yapılmıştır. Bunun amacı gradiant vanishing/explosing gibi problemleri önlemek ve sınıflandırma performansını arttırmak için yapmıştır. Sınıflandırma aşamasından önceği katman da ise global average pooling (GAP) kullanılmıştır ve daha sonra klasik sinir ağına verilip sınıflandırma yapılmıştır. Kayıp fonksiyonu olarak cross entropy loss kullanılmıştır. Residual blokları için relu kullanılmıştır. Son katman çıkışı olarak da sigmoid kullanılmıştır [16].Şekil 3.4’de anlatılan modelin görsel hali verilmiştir.



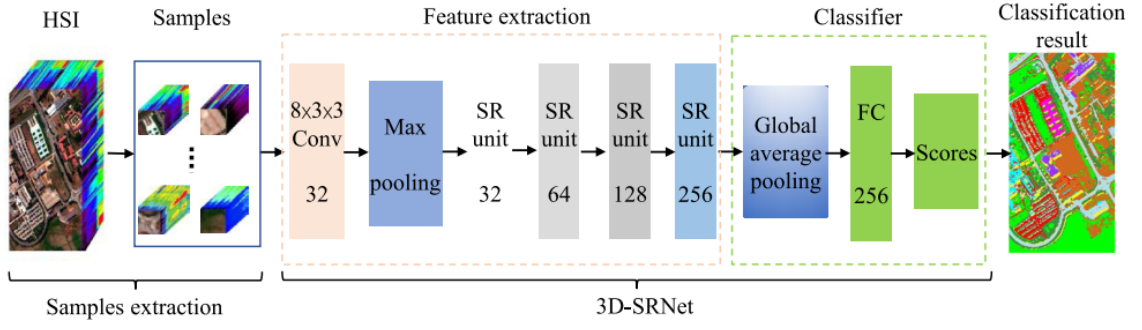
Şekil 3.4: GAO modelinin genel olarak çalışma şekli

Giriş görüntüleri patchlere bölünüyor preporcessing olarak. Daha sonra spectral feature extraction için Evrişim  $1 \times 1$  ve ReLU uygulanıyor. Bu işlemin ardından çoklu spectral-spatial feature learning işlemleri yapılıyor. Yanda görsel olarak verildiği gibi. Bu aşamadan sonra concatenated yapılp feature fusion yaparak devam ediyor. Çıkış katmanında ise softmax kullanıyor [17]. Şekil 3.5'de anlatılan modelin görsel hali verilmiştir.



Şekil 3.5: SSDC-DenseNet modelinin genel olarak çalışma şekli

İki aşamalı bir modeldir. İlk aşamada samples extranctions , yani örneklerden özellik çıkarma işlemi yapılıyor. Sonra 3B-SRNet ağı ile özellik çıkarımı ve sınıflandırma işlemi yapıyor [18]. Şekil 3.6’de anlatılan modelin görsel hali verilmiştir.



Şekil 3.6: 3D-SRNet modelinin genel olarak çalışma şekli

#### 4. Konuyla İlgili Çalışmalar

Giriş ve Motivasyon: Uzaktan algılama verilerini kullanan hava sahnesi sınıflandırması, verilerin özelliklerinden dolayı (az sayıda etiketli veri bulunması ve yüksek boyutluluk) hem askeri hem de sivil alanlarda en zorlu araştırma alanlarından biridir [19]. Hiperspektral görüntü küpleri, farklı elektromanyetik spektrumlardan (spektral bantlardan) alınan yüzlerce veya binlerce uzamsal görüntüden oluşur. Bu nedenle, araştırma yapanlara aynı anda hem uzamsal hem de spektral bilgi sunarlar. Hiperpektral görüntülerin spektral çözünürlüğü yüksektir. Çünkü elektromanyetik spektrumdan (10-20 nm) dar bantlarda görüntüler almaktadır. Hiperspektral görüntüleme teknolojinin gelişmesiyle birçok ülke bu alana odaklanmıştır. Örneğin, Almanya'nın Environmental Mapping and Analysis Programı (EnMAP), Dünya'nın çevresini küresel ölçekte izlemeyi ve nitelendirmeyi hedeflemektedir. Bu durum günden güne uzaktan algılama görüntülerindeki artışa paralel olarak hiperspektral veri ambarlarında artışa neden olmaktadır. Bunun sonucunda da, görüntülerdeki gizli bilgilerin açığa çıkarılabilmesine imkân tanınmaktadır. Ancak, bu bilgilerin nasıl kullanılacağı daha fazla araştırma gerektiren açık bir konudur. Son yıllarda, birçok gerçek dünya görüntü tanıma uygulaması -özellikle yer bilimi ve uzaktan algılama alanında-, klasik makine öğrenme araçlarına kıyasla (ham veriden etkin özellik çıkartabilme yeteneğinden kaynaklanan) üstün performansı nedeniyle derin öğrenme tekniklerine büyük ilgi göstermektedir. “Derin öğrenme, çok sayıda doğrusal olmayan dönüşümlerden oluşan mimarileri kullanarak verilerde üst düzey soyutlamaları modelleyen bir dizi makine öğrenme algoritmasıdır”[20]. Adından da anlaşılacağı gibi, Derin Sinir ağları hiyerarşik olarak düzenlenmiş birden fazla gizli katmana sahiptir. Ön katmanlarda basit bilgiler (kenarlar gibi) çıkarılmakta ve sonraki seviyelere iletilmektedir. Bu şekilde, sonraki seviyeler orta seviye bilgileri çıkarmaktadır. Bu işlem (bazı bilgileri girdi olarak alıp çıkış katmanında daha karmaşık bilgileri çıkartma) ağ hiyerarşisi sonuna kadar tekrar eder.

Özellikle, Evrişimli Sinir Ağları (Convolutional Neural Networks = CNN) [21] birçok bilgisayarlı görme problemi için güçlü bir araçtır. Diğer derin öğrenme algoritmalarından farklı olarak, CNN'ler, katlama – evrişim- (filtreleme) işleminin görüntünün belirli bir alıcı alanı (receptive field) üzerinde gerçekleştirildiği evrişim katmanlarını içerir. Derin Öğrenme mimarileri uzaktan algılamada birçok amaç için kullanılabilir: görüntü ön işleme, piksel tabanlı sınıflandırma, hedef tanıma, anlamsal özellik çıkarma ve sahne anlamlandırma. Derin Öğrenmenin uzaktan algılama verilerinde kullanımı bazı nedenlerden dolayı ekstra motivasyona sahiptir: 1) Uzaktan algılama verileri (özellikle çok bantlı ve hiperspektral görüntüler), çoklu spektral bantlar içerir. Bu, birkaç görüntüde bile veri miktarının çok büyük olduğu anlamına gelir. Bu yüzden daha fazla nörona ve daha derin sinir ağlarına ihtiyaç duymaktadır [22]. 2) Uzaktan algılama görüntüleri, doğal sahne görüntülerinden daha karmaşıktır. Farklı renk, konum, boyut ve yönelime sahip çeşitli nesne türlerinden oluşabilir. Bu karmaşıklık, doğal (natural) görüntü tanıma için ortak bir yaklaşım olan transfer öğrenmenin başarılı bir şekilde uygulanmasına engel olur. Transfer öğrenmede, derin öğrenme modeli çok sayıda etiketli numuneye sahip olan bir veri seti ile (ImageNet gibi) ön eğitimden geçirilmiştir. Ardından, sınırlı eğitim numuneleriyle sadece modelin son 2 veya 3 tam bağlı katmanını yeniden eğitilerek (önceki katmanlar değil) model parametreleri (ağırlıklar) güncellenir. Ayrıca, görsel farklılıklara 4 neden olan farklı sensörlerle görüntüler çekilebilir. 3) Her ne kadar derin öğrenme yöntemleri çok sayıda etiketlenmiş veri ile mükemmel bir performans sergilese de, uzaktan algılamada yalnızca sınırlı sayıda etiketli veri bulunmaktadır. Bu durum derin öğrenme yöntemlerinin performansını sınırlamaktadır. Yukarıda belirtilen nedenlerden ötürü, hiperspektral uzaktan algılama için en uygun derin sinir ağı mimarisinin geliştirilmesi zorlayıcı ve popüler bir araştırma alanıdır.

Son zamanlarda, derin öğrenmenin doğal görüntü işleme alanındaki başarısını takiben, bu yöntemler HSI (Hyper-spectral Imaging = Hiperspektral görüntüleme) sınıflamasına da uygulanmış ve etkileyici sonuçlar elde edilmiştir [23] [24] [25]. Bu yaklaşımlar sırasıyla spektral bilgiden, uzamsal bilgiden ve spektral-uzamsal bilgiden faydalananlar olarak üç ana kategoride ele alınabilir. Uzamsal çözünürlük ile karşılaştırıldığında, spektral çözünürlük nispeten daha yüksektir. Her bir pikselden bir spektral vektör çıkarılabilir ve bu uzamsal piksele gömülü bilgi içeriğini tanımlamak için kullanılır. Geleneksel HSI sınıflandırma yaklaşımları yalnızca spektral bilgileri kullanır. Tipik sınıflandırıcılar arasında k-en yakın



komşuluk [25], uzaklık ölçütü [26], lojistik regresyon [27], ve en büyük olabilirlik kriteri [28] temelinde uygulanmış olanlar yer almaktadır. Her pikseli doğrudan spektral vektör üzerinden sınıflandırmak çoğu zaman makul ve verimli değildir.

Literatürdeki geleneksel HSI sınıflandırma yaklaşımlarında, sınıflandırmayı desteklemek için özellik çıkarma yöntemleri de uygulanmıştır. Uzamsal özellikler genellikle tek bantlı bir görüntüden elde edilir. Günümüzde, uzamsal özellikler yaygın olarak 2D görüntü tarzında çalışan geleneksel Evrişimli Sinir Ağları (örneğin AlexNet [29], GoogLeNet [30], ResNet [31] ile çıkarılmaktadır. Bununla birlikte, hiperspektral görüntülerde kullanılan bantların sayısı çok yüksek olduğundan, işlemci teknolojisi gelişmiş olsa bile, bir bütün olarak 2D Evrişimli Sinir Ağlarına (CNN) bir girdi olarak verilemez. Bu nedenle, genellikle minimal 1D CNN mimarileri (evrişim katmanı + havuz katmanı + tam bağlı katman) [9] spektral özellik çıkarımı için kullanılır. Ayrıca, hesaplama maliyetini azaltmak ve ağ eğitimini geliştirmek için literatürde dropout ve batch normalization [32] teknikleri kullanılmaktadır. Giriş görüntülerini 1D vektörler olarak alan danışmansız derin öğrenme yaklaşımları (örneğin stacked auto encoders ve deep belief networks gibi) aynı zamanda temsil yeteneği olan spektral özellikleri ortaya çıkarmak için de kullanılır. Uzamsal ve spektral özelliklerin 2D ve 1D derin öğrenme mimarilerinden ayrı olarak çıkarılması, son işlem olarak bir birleştirme (fusion) stratejisi gerektirir. Bu doğrultuda ilk çalışma [8], yazarların derin spektral özelliği çıkarmak için bir SAE (stacked auto encoder) kullandığı çalışmadır. Bu orijinal çalışmanın ardından, SAE yerine DBN (Deep Belief Network) kullanımı bildirilmiştir [24]. Benzer şekilde, [33] nolu çalışma etkin özelliği öğrenmek ve ince ayar işleminde önsel göreceli bir mesafe eklemek için SAE'yi kullanmıştır.

Böylece yeterli sayıda etiketli örnek olmadığında istenen özelliklere ilişkin daha etkin bir yönlendirme sağlanmıştır. [34], güçlü spektral özellikleri ayıklamak ve sınıflandırma işlemini tamamlamak için stacked denoising auto encoder ağını [35] kullanmıştır. Benzer bir fikir [36] nolu çalışmada benimsenmiştir. Burada, HSI, deep stacking network (DSN) adı verilen yeni bir model ile sınıflandırılmıştır. Bir DSN modeli, her biri bir giriş katmanı, gizli 5 katman ve bir çıkış katmanı içeren birçok basit modülü içerir. Burada giriş katmanından gizli katmana ağırlıklar rasgele veya kontrastlı sapmalarla [37], gizli katmandan çıkış katmanına ise yalancı ters alma işlemi ile başlatılır. Zhong vd. [38] HSI'daki sınıflandırma

verimliliğini artırmaya yardımcı olan DBN'nin ön eğitim ve ince ayar işlemlerinde eğitim hedefinin optimizasyonuna çeşitliliği teşvik edici koşulları dâhil etmiştir.

Yukarıda açıklanan spektral özellik çıkartma yöntemleri sadece spektral bilgileri kullanır ve uzamsal bilgileri kullanmaz. Oysa uzamsal bilgi, görüntüdeki komşu pikseller arasında ani bir değişiklik olmadığı hipotezine dayanmaktadır. Bu amaçla, ön işleme olarak, spektral bantları azaltmak için Temel Bileşen Analizi tekniği kullanılır. Daha sonra, derin spektral / uzamsal özellikler elde etmek için tüm hiperspektral görüntü küpüne 2D CNN uygulanır [39].

Diğer bir yeni çalışma [6] nolu çalışmada önerilmiştir. Burada, uzamsal özellikleri genişletmek için, derin CNN kullanımına dayalı HSI yeniden yapılandırma modeli önerilmiştir. Benzer fikirle, [8] ve [40] nolu çalışmalarda PCA, HSI görüntülerinin boyutsallığını azaltmak için kullanılır. Ortaya çıkan veri küpleri tek boyuta indirgenir veya komşu bölgelerden çıkarılır. Bunu daha sonra, sınıflandırma işlemini gerçekleştiren bir SAE izler.

Temel derin öğrenme modelleri (SAE, CNN ve DBN) dışında, son zamanlarda sıralı verilerden yararlanan Recurrent Neural Networks (RNN) de spektral bantların sürekliliğini modellemek için hiperspektral görüntü sınıflandırmasında kullanılmaktadır. Piksel tabanlı sınıflandırma yaklaşımlarından ayrı olarak, bir başka bakış açısı da bütün görüntüyü yerel görüntü patch'lerine bölmek ve her bir patch'i önceden tanımlanmış semantik etiketlerden birine (endüstriyel alan veya yerleşim alanı gibi) atamaktır. Bu top-down yaklaşım genellikle sahne sınıflandırması olarak adlandırılır. Günümüzde bu sınıflandırma yaklaşımı, derin öğrenme mimarileri ile birlikte kullanılmaktadır.

## 5. Sonular


Geliřtirmiř olduėumuz 3B-ESA-VAE modeli iyi sonular retmiřtir. Bu model Indian Pines ve Salinas veriseti zerinde test edilmiřtir. Doėruluk deėerleri eřitli hiper parametlere gre deėiřmektedir. Bunun sebebi ise hızlı ėrenim yapması, ařırı ėrenme vb. olarak syleyebiliriz.




řekil 5.1: Indian Pines hedef sınıflandırma grnts



řekil 5.2: Indian Pines tahmin sonucu oluřan ıktı



Şekil 5.3: Salinas orjinal hedef sınıflandırma görüntüsü



Şekil 5.4: Salinas tahmin sonucu oluşan çıktı

Tablo 5.1: Sonuçların sayısal değerleri

Veriseti Adı	Kappa(%)	Ortalama Doğruluk	Genel Doğruluk
Indian Pines	0.989	99.038	99.038
Salinas	0.999	99.881	99.881

Geliştirmiş olduğumuz modelin Tablo 5.1’de Şekil 5.2 ve Şekil 5.4 resimlerin orjinal resim ile karşılaştırmasının sayısal sonuçları verilmiştir.

## 6. Kaynaklar

- [1] Enrico Blanzieri and Farid Melgani. “Nearest neighbor classification of remote sensing images with the maximal margin principle”. In: *IEEE Transactions on geoscience and remote sensing* 46.6 (2008), pp. 1804–1811.
- [2] Farid Melgani and Lorenzo Bruzzone. “Classification of hyperspectral remote sensing images with support vector machines”. In: *IEEE Transactions on geoscience and remote sensing* 42.8 (2004), pp. 1778–1790.
- [3] Frédéric Ratle, Gustavo Camps-Valls, and Jason Weston. “Semisupervised neural networks for efficient hyperspectral image classification”. In: *IEEE Transactions on Geoscience and Remote Sensing* 48.5 (2010), pp. 2271–2282.
- [4] Xudong Kang et al. “Intrinsic image decomposition for feature extraction of hyperspectral images”. In: *IEEE Transactions on Geoscience and Remote Sensing* 53.4 (2014), pp. 2241–2253.
- [5] Yuliya Tarabalka et al. “SVM-and MRF-based method for accurate classification of hyperspectral images”. In: *IEEE Geoscience and Remote Sensing Letters* 7.4 (2010), pp. 736–740.
- [6] Yunsong Li, Weiying Xie, and Huaqing Li. “Hyperspectral image reconstruction by deep convolutional neural network for classification”. In: *Pattern Recognition* 63 (2017), pp. 371–383.
- [7] Shiqi Yu, Sen Jia, and Chunyan Xu. “Convolutional neural networks for hyperspectral image classification”. In: *Neurocomputing* 219 (2017), pp. 88–98.
- [8] Yushi Chen et al. “Deep learning-based classification of hyperspectral data”. In: *IEEE Journal of Selected topics in applied earth observations and remote sensing* 7.6 (2014), pp. 2094–2107.
- [9] Wei Hu et al. “Deep convolutional neural networks for hyperspectral image classification”. In: *Journal of Sensors* 2015 (2015).
- [10] Jaime Zabalza et al. “Novel segmented stacked autoencoder for effective dimensionality reduction and feature extraction in hyperspectral imaging”. In: *Neurocomputing* 185 (2016), pp. 1–10.
- [11] Wei Li et al. “Hyperspectral image classification using deep pixel-pair features”. In: *IEEE Transactions on Geoscience and Remote Sensing* 55.2 (2016), pp. 844–853.
- [12] Diederik P Kingma and Max Welling. “Auto-encoding variational bayes”. In: *arXiv preprint arXiv:1312.6114* (2013).
- [13] Simin Li et al. “Adaptive spatial-spectral feature learning for hyperspectral image classification”. In: *IEEE Access* 7 (2019), pp. 61534–61547.
- [14] Ji He et al. “HSI-BERT: Hyperspectral Image Classification Using the Bidirectional Encoder Representation From Transformers”. In: *IEEE Transactions on Geoscience and Remote Sensing* 58.1 (2019), pp. 165–178.

- [15] Swalpa Kumar Roy et al. “HybridSN: Exploring 3-D–2-D CNN feature hierarchy for hyperspectral image classification”. In: *IEEE Geoscience and Remote Sensing Letters* 17.2 (2019), pp. 277–281.
- [16] Hongmin Gao et al. “Hyperspectral Image Classification With Pre-Activation Residual Attention Network”. In: *IEEE Access* 7 (2019), pp. 176587–176599.
- [17] Yutong Bai et al. “SSDC-DenseNet: A Cost-Effective End-to-End Spectral-Spatial Dual-Channel Dense Network for Hyperspectral Image Classification”. In: *IEEE Access* 7 (2019), pp. 84876–84889.
- [18] Yenan Jiang, Ying Li, and Haokui Zhang. “Hyperspectral image classification based on 3-D separable ResNet and transfer learning”. In: *IEEE Geoscience and Remote Sensing Letters* 16.12 (2019), pp. 1949–1953.
- [19] Ying Li et al. “Deep learning for remote sensing image classification: A survey”. In: *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 8.6 (2018), e1264.
- [20] Yong Yan et al. “Application of soft computing techniques to multiphase flow measurement: A review”. In: *Flow Measurement and Instrumentation* 60 (2018), pp. 30–43.
- [21] Yann LeCun et al. “Gradient-based learning applied to document recognition”. In: *Proceedings of the IEEE* 86.11 (1998), pp. 2278–2324.
- [22] Xueyun Chen et al. “Aircraft detection by deep belief nets”. In: *2013 2nd IAPR Asian Conference on Pattern Recognition*. IEEE. 2013, pp. 54–58.
- [23] Yushi Chen et al. “Deep feature extraction and classification of hyperspectral images based on convolutional neural networks”. In: *IEEE Transactions on Geoscience and Remote Sensing* 54.10 (2016), pp. 6232–6251.
- [24] Yushi Chen, Xing Zhao, and Xiuping Jia. “Spectral–spatial classification of hyperspectral data based on deep belief network”. In: *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 8.6 (2015), pp. 2381–2392.
- [25] Luis Samaniego, András Bárdossy, and Karsten Schulz. “Supervised classification of remotely sensed imagery using a modified  $k$ -NN technique”. In: *IEEE Transactions on Geoscience and Remote Sensing* 46.7 (2008), pp. 2112–2125.
- [26] Qian Du and Chein-I Chang. “A linear constrained distance-based discriminant analysis for hyperspectral image classification”. In: *Pattern Recognition* 34.2 (2001), pp. 361–373.
- [27] Jun Li, José M Bioucas-Dias, and Antonio Plaza. “Semisupervised hyperspectral image segmentation using multinomial logistic regression with active learning”. In: *IEEE Transactions on Geoscience and Remote Sensing* 48.11 (2010), pp. 4085–4098.
- [28] Jayantha Ediriwickrema and Siamak Khorram. “Hierarchical maximum-likelihood classification for improved accuracies”. In: *IEEE Transactions on Geoscience and Remote Sensing* 35.4 (1997), pp. 810–816.

- [29] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. “ImageNet Classification with Deep Convolutional Neural Networks”. In: *Advances in Neural Information Processing Systems*. Ed. by F. Pereira et al. Vol. 25. Curran Associates, Inc., 2012, pp. 1097–1105. URL: <https://proceedings.neurips.cc/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf>.
- [30] Christian Szegedy et al. “Going deeper with convolutions”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2015, pp. 1–9.
- [31] Kaiming He et al. “Deep residual learning for image recognition”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, pp. 770–778.
- [32] Yong Xu et al. “A regression approach to speech enhancement based on deep neural networks”. In: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 23.1 (2014), pp. 7–19.
- [33] Xiaorui Ma et al. “Hyperspectral image classification with small training set by deep network and relative distance prior”. In: *2016 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)*. IEEE. 2016, pp. 3282–3285.
- [34] Chen Xing, Li Ma, and Xiaoquan Yang. “Stacked denoise autoencoder based feature extraction and classification for hyperspectral images”. In: *Journal of Sensors* 2016 (2016).
- [35] Pascal Vincent et al. “Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion.” In: *Journal of machine learning research* 11.12 (2010).
- [36] Mingyi He et al. “Hyperspectral image classification based on deep stacking network”. In: *2016 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)*. IEEE. 2016, pp. 3286–3289.
- [37] Geoffrey E Hinton. “Training products of experts by minimizing contrastive divergence”. In: *Neural computation* 14.8 (2002), pp. 1771–1800.
- [38] P Zhong, ZQ Gong, and C Schönlieb. “A diversified deep belief network for hyperspectral image classification”. In: *Int Arch Photogram Remote Sens Spatial Inform Sci* 41 (2016), pp. 443–449.
- [39] Heming Liang and Qi Li. “Hyperspectral imagery classification using sparse representations of convolutional neural network features”. In: *Remote Sensing* 8.2 (2016), p. 99.
- [40] Zhouhan Lin et al. “Spectral-spatial classification of hyperspectral image using autoencoders”. In: *2013 9th International Conference on Information, Communications & Signal Processing*. IEEE. 2013, pp. 1–5.